

ANO

2022



UNINTER

**CADERNO DE RESPOSTAS DA
ATIVIDADE PRÁTICA DE:**

PROJETOS BIG DATA

ALUNO: ESTHER MARA BALDUÍNO DE PAULO RU:

Caderno de Resposta Elaborado por:
Prof. MSc. Guilherme Ditzel Patriota

Prática 01 – Somatório de IDs

Questão – Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”

ENUNCIADO: Nessa prática você deverá descobrir, utilizando sua máquina virtual com o Hadoop ou Spark ou PySpark, qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”.

I. Apresentação do Código (não esquecer do identificador pessoal):

```
1 def map1(x):
2     # Esta função deve retornar uma tupla (sentiment, id).
3     # o argumento de entrada x é uma linha do dataframe imdb_df
4     # com os dados em um formato semelhante à um dicionário
5     # Apague a linha abaixo para iniciar seu código.
6     return (x[3], int(x[0])) # (sentiment, id convertido para int)
7
8
```

```
1 def reduceByKey1(x,y):
2     # Coloque aqui o seu código para retornar o resultado necessário.
3     # x e y são valores que serão somados, pois o reduceByKey receberá
4     # apenas o segundo elemento da tupla vinda da saída da função map.
5     # Apague a linha abaixo para iniciar seu código.
6     return x + y # Soma os IDs associados ao mesmo 'sentiment'
7
8
```

```
1 # Linha de código para aplicar o map/reduce no seu dataframe spark
2 resultado = imdb_df.rdd.map(map1).reduceByKey(reduceByKey1).collect()
3 # Coloque aqui o código para imprimir o resultado.
4 # Não esqueça seu RU:
5 # Filtra para exibir apenas os resultados com sentimento 'neg'
6 resultado_negativo = [item for item in resultado if item[0] == 'neg']
7 ru = "4328984"
8 print(f"Soma dos IDs dos sentimentos negativos: {resultado_negativo}")
9 print(f"RU: {ru}")
```

Figura 1: Visualização do código utilizado para contar palavras nos textos negativos de filmes e somar os id dos filmes classificados como negativos, conforme o enunciado.

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

```
Soma dos IDs dos sentimentos negativos: [['neg', 459568555]]
RU: 4328984
```

Figura 2: Resultado final da execução do código, mostrando a soma dos id dos filmes classificados como negativos.

III. Responda à pergunta: Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos?

Resposta: 459568555

Prática 02 – Diferença do número de palavras totais de português para inglês dos textos negativos

Questão – Contar palavras dos textos negativos e achar diferença de quantidade.

ENUNCIADO: Nessa prática você deverá contar todas as palavras existentes nos textos negativos (Português e Inglês) e então deverá encontrar quantas palavras a mais, no total, os textos em português possuem.

Para tal, crie um script em Python ou Scala e rode-o com sua máquina virtual Hadoop ou Spark ou PySpark, como feito na prática 1.

É necessário se preocupar em filtrar corretamente as avaliações de filmes para que apenas os textos marcados como negativos sejam contabilizados.

I. Apresentação do Código (não esquecer do identificador pessoal):

```
1 def map2(x):
2     # Coloque aqui o seu código para retornar a tupla necessária.
3     # Sugérons o retorno em uma tupla com este formato:
4     # (sentiment, (quantidade_de_palavras_em_en, quantidade_de_palavras_em_pt))
5     # OU
6     # (sentiment, quantidade_de_caracteres_em_pt-quantidade_de_caracteres_em_en)
7     # Apague a linha abaixo para iniciar seu código.
8     sentiment = x[3] # Sentimento (índice 3)
9     text_en = x[1] # Texto em inglês (índice 1)
10    text_pt = x[2] # Texto em português (índice 2)
11
12    # Conta palavras em cada idioma
13    word_count_en = len(text_en.split()) # Número de palavras em inglês
14    word_count_pt = len(text_pt.split()) # Número de palavras em português
15    # Retorna a tupla no formato (sentiment, (word_count_en, word_count_pt))
16    return (sentiment, (word_count_en, word_count_pt))
```

```
41 def reduceByKey(x,y):
2     # Coloque aqui o seu código para retornar o resultado necessário.
3     # x e y são valores que podem ser ou a tupla vinda da saída da função map
4     # contendo quantidade de palavras em inglês e português, ou a diferença, a
5     # depender da sua implementação da função map2.
6     # Apague a linha abaixo para iniciar seu código.
7     total_en = x[0] + y[0] # Soma das palavras em inglês
8     total_pt = x[1] + y[1] # Soma das palavras em português
9     return (total_en, total_pt)
```

```
1 # Linha de código para aplicar o map/reduce no seu dataframe spark
2 resultado = indb_df.rdd.map(map2).reduceByKey(reduceByKey2).collect()
3 # Coloque aqui suas linhas de código final para imprimir o resultado.
4 # Não esqueça seu RU:
5 # Filtra e calcula a diferença para o sentimento "neg"
6 resultado_negativo = [item for item in resultado if item[0] == 'neg']
7 diferenca = resultado_negativo[0][1][1] - resultado_negativo[0][1][0] # Subtrai pt de en
8
9 # Imprimi o resultado
10 ru = "4328984" # RU
11 print(f"A diferença no número de palavras entre os textos negativos em português e inglês é: (diferença) palavras.")
12 print(f"RU: {ru}")
```

Figura 3: Visualização do código utilizado para mostrar a diferença entre a contagem de palavras nos textos em português e inglês para filmes com sentimento negativo.

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

A diferença no número de palavras entre os textos negativos em português e inglês é: 54949 palavras.
RU: 4328984

Figura 4: Saída do código que calcula a diferença no número de palavras entre os textos negativos em português e inglês. Mostra a diferença total de palavras, com base nos textos classificados como negativos.

III. Responda à pergunta: Qual o número total de palavras a mais que os textos negativos em português possuem em comparação com a soma total das palavras dos textos negativos em inglês, independentemente de serem repetidas?

Resposta: 54949